

```
▶ !nvcc task1_reduction.cu -o task1
!./task1

... TASK 1 – Reduction
CPU sum = 511.593
GPU sum = 0
Diff    = 511.593
```

```
[3]
✓ 3 сек. !nvcc -O3 -std=c++17 task2_scan.cu -o task2
!./task2

▼ TASK 2 – Prefix sum
Last element = 0 (expected 1024)
```

```
[4]
✓ 2 сек. !nvcc -O3 -std=c++17 task3_benchmark.cu -o task3
!./task3

▼ TASK 3 – Benchmark
GPU time: 7.2664 ms
CPU time: 0.00301 ms
```

Контрольные вопросы

1. В чём разница между редукцией и сканированием?

Редукция — это операция сведения массива к одному значению (сумма, минимум, максимум).

Сканирование (prefix sum) — это операция, при которой вычисляется накопленный результат для каждого элемента.

Пример:

[1, 2, 3, 4]

Редукция → 10

Сканирование → [1, 3, 6, 10]

2. Какие типы памяти CUDA используются для оптимизации?

- Глобальная память — хранение входных и выходных данных
- Разделяемая память (shared) — ускорение доступа внутри блока
- Регистры — локальные переменные потоков

В данной работе ключевую роль играет shared memory.

3. Как можно оптимизировать префиксную сумму на GPU?

- Использовать Blelloch Scan (upsweep + downsweep)
 - Минимизировать `__syncthreads()`
 - Выполнять scan иерархически (block → grid)
 - Использовать warp-level primitives (`__shfl_*`)
-

4. Приведите пример задачи, где применяется сканирование

- Построение гистограмм
- Stream compaction
- Сортировка (Radix Sort)
- Генерация индексов
- Алгоритмы графов (BFS)